

Aplicação de Modelos de Linguagem na Recuperação de Itens em Bases Comerciais

Title: Application of Language Models in Item Retrieval from Commercial Databases

Kleidson Matos da Rocha¹, Fabio Zanin¹

¹ Universidade Regional Integrada do Alto Uruguai e das Missões
Departamento de Engenharias e Ciência da Computação
Caixa Postal 743 – 99.709-910 – Erechim – RS – Brasil

105087@uricer.edu.br, orientador@uricer.edu.br

Abstract. Introduction: Efficient product retrieval in commercial databases is a recurring challenge, especially when users provide incomplete or imprecise descriptions.

Objective: To develop an item retrieval system assisted by a pre-trained language model adapted to a specific domain.

Methodology: Exploratory research involving literature review, domain adaptation of a pre-trained model using efficient fine-tuning techniques, prototype development, and validation through comparative tests.

Expected Results: To improve interpretation of user queries, identify missing search requirements, and increase the relevance of retrieved items.

Keywords LLM, Fine-Tuning, Recuperação de Informação, Inteligência Artificial, Banco de Dados.

Resumo. Introdução: A busca eficiente por produtos em bases de dados comerciais é um desafio recorrente, especialmente quando os usuários utilizam descrições incompletas ou imprecisas.

Objetivo: Desenvolver um sistema de recuperação de itens baseado em um modelo de linguagem pré-treinado adaptado a um domínio específico.

Metodologia: Pesquisa exploratória com revisão bibliográfica, adaptação de modelo pré-existente por técnicas eficientes de fine-tuning, desenvolvimento de protótipo e validação por meio de testes comparativos.

Resultados Esperados: Melhorar a interpretação das consultas, identificar requisitos ausentes e aumentar a relevância dos itens retornados.

Palavras-Chave LLM, Fine-Tuning, Recuperação de Informação, Inteligência Artificial, Banco de Dados.

1. Introdução

O avanço das tecnologias digitais e o crescimento do comércio eletrônico têm ampliado significativamente o volume de dados disponíveis em bases comerciais. Nesse contexto, sistemas de busca desempenham papel fundamental na recuperação eficiente de informações.

Entretanto, a recuperação de itens ainda apresenta desafios relevantes. Usuários frequentemente utilizam descrições incompletas, termos informais ou informações parciais, dificultando a correspondência direta com dados estruturados.

Diante desse cenário, torna-se necessário investigar abordagens que permitam melhor interpretação das consultas, considerando contexto e intenção.

Adicionalmente, será desenvolvido um protótipo funcional baseado na adaptação de um modelo de linguagem pré-treinado ao domínio de autopeças, com o objetivo de simular o

comportamento de um vendedor especializado. O sistema será capaz de interpretar consultas, identificar requisitos necessários, solicitar informações adicionais quando necessário e realizar buscas estruturadas para retornar itens relevantes.

2. Justificativa

No contexto do comércio de autopeças, a busca por produtos é tradicionalmente realizada de forma manual, a partir da interação entre cliente e vendedor. Nesse processo, o cliente realiza sua solicitação, geralmente por meio de aplicativos de mensagens, e o vendedor interpreta a necessidade e realiza a busca no sistema ERP da empresa.

Entretanto, esse modelo apresenta limitações relevantes. A dependência da interpretação humana torna o processo suscetível a inconsistências, como erros na identificação de peças, influência de preferências pessoais do vendedor (por exemplo, priorização de determinadas marcas) e variação de qualidade conforme a experiência do atendente. Além disso, a necessidade de informações completas para realizar a busca pode gerar atrasos no atendimento, especialmente quando o cliente fornece descrições incompletas ou imprecisas.

Esse cenário é agravado pelo volume de atendimentos. Em situações reais, observa-se uma demanda superior à capacidade operacional da equipe, resultando em clientes não atendidos ou que desistem da compra devido à demora.

Os sistemas atuais, baseados em busca por termos específicos ou aplicações padronizadas, apresentam limitações na interpretação de linguagem natural, exigindo que o usuário forneça descrições estruturadas e completas. Essa abordagem não é compatível com o comportamento real dos clientes, que frequentemente utilizam linguagem informal, incompleta ou ambígua.

Diante desse contexto, justifica-se a aplicação de modelos de linguagem pré-treinados adaptados ao domínio de autopeças, com o objetivo de atuar como um agente conversacional capaz de interpretar consultas em linguagem natural, identificar informações ausentes, interagir com o usuário para complementar os requisitos e realizar a recuperação de itens de forma mais eficiente.

Diferentemente das abordagens tradicionais, a proposta deste trabalho busca não apenas melhorar a busca, mas sim automatizar o fluxo de atendimento, simulando o comportamento de um vendedor especializado. Espera-se, com isso, reduzir o tempo de resposta, minimizar erros na seleção de peças, padronizar o atendimento e aumentar a capacidade de atendimento da empresa, contribuindo diretamente para a melhoria da eficiência operacional e potencial aumento de conversão de vendas.

3. Objetivos

3.1. Objetivo Geral

Desenvolver um sistema de recuperação de itens assistido por um modelo de linguagem pré-treinado adaptado a um domínio específico.

3.2. Objetivos Específicos

- Investigar modelos de linguagem aplicáveis à recuperação de informação em linguagem natural
- Adaptar um modelo pré-treinado ao domínio de autopeças
- Desenvolver um agente conversacional capaz de interpretar consultas e interagir com o usuário
- Implementar mecanismo de identificação e complementação de requisitos de busca
- Integrar o agente a uma base de dados comercial para recuperação de itens
- Construir um protótipo funcional do sistema
- Avaliar o desempenho do sistema em cenários reais de consulta

4. Escopo

Este trabalho tem como foco o desenvolvimento de um sistema de recuperação de itens em bases comerciais, utilizando um modelo de linguagem pré-treinado adaptado a um domínio específico.

Inclui:

- Desenvolvimento de um sistema de busca assistido por modelo de linguagem adaptado
- Interpretação de consultas em linguagem natural
- Identificação de requisitos de busca a partir da intenção do usuário
- Integração do modelo com banco de dados para recuperação de itens

Não inclui:

- Treinamento de modelo de linguagem do zero
- Desenvolvimento de um sistema comercial completo ou ambiente de produção

5. Metodologia

Implementação da lógica de interpretação de consultas e interação com o usuário para obtenção de informações faltantes

1. Levantamento de requisitos e fundamentação teórica

Nesta etapa será realizada a revisão bibliográfica sobre recuperação de informação, modelos de linguagem e técnicas de adaptação. Também serão analisados:

- Modelos base mais adequados ao problema
- Estratégias de adaptação ao domínio
- Requisitos técnicos de infraestrutura (hardware e servidor)

2. Desenvolvimento de protótipo de validação

Com base no levantamento técnico, será desenvolvido um protótipo inicial com o objetivo de validar as decisões arquiteturais. Esta etapa inclui:

- Adaptação de um modelo pré-treinado ao domínio de autopeças
- Implementação da lógica de interpretação de consultas
- Integração com base de dados
- Construção do fluxo de busca de itens

3. Desenvolvimento do sistema final

Após validação do protótipo, será realizada a evolução para uma versão mais estruturada do sistema, contemplando:

- Refinamento da arquitetura
- Melhoria da interpretação semântica
- Otimização da recuperação de itens

4. Validação e testes

Serão realizados testes utilizando consultas reais, incluindo:

- Consultas incompletas
- Consultas ambíguas
- Avaliação da relevância dos resultados retornados

Essa etapa visa medir o desempenho do sistema e sua capacidade de simular um atendimento comercial automatizado.

6. Ferramentas

6.1. Hardware

- Computador pessoal para desenvolvimento e testes
- Servidor ou máquina virtual para execução dos modelos e serviços

6.2. Software

- Python
- PostgreSQL
- Docker
- Modelo de Linguagem Pré-treinado (LLM)
- APIs
- Git

Cronograma

[illegible]

7. Resultados Esperados

Espera-se que o sistema desenvolvido seja capaz de interpretar consultas em linguagem natural, mesmo quando estas forem incompletas, imprecisas ou ambíguas, refletindo de forma mais fiel o comportamento real dos clientes no contexto comercial. Além disso, o sistema deverá identificar informações ausentes durante o processo de busca, sendo capaz de interagir com o usuário para complementar os requisitos necessários à recuperação adequada dos itens.

Com a aplicação dessa abordagem, espera-se uma redução no tempo médio de atendimento em comparação ao processo manual atualmente realizado por vendedores, bem como uma diminuição na ocorrência de erros relacionados à seleção de peças. Adicionalmente, o sistema tende a promover a padronização do processo de busca, reduzindo variações decorrentes da experiência ou de decisões subjetivas dos atendentes.

Por fim, espera-se que a solução proposta contribua para o aumento da capacidade de atendimento simultâneo, permitindo que um maior número de clientes seja atendido de forma eficiente, o que pode impactar positivamente a conversão de vendas e a eficiência operacional do ambiente comercial.

8. Referências

BROWN, T. et al. Language Models are Few-Shot Learners. 2020.

DEVLIN, J. et al. BERT. 2019.

MANNING, C. Introduction to Information Retrieval. 2008.