

Aplicação de Modelos de Linguagem na Recuperação de Itens em Bases Comerciais

Title: Application of Language Models in Item Retrieval from Commercial Databases

Kleidson Matos da Rocha¹, Marcos Lucas¹

¹ Universidade Regional Integrada do Alto Uruguai e das Missões
Departamento de Engenharias e Ciência da Computação
Caixa Postal 743 – 99.709-910 – Erechim – RS – Brasil

105087@uricer.edu.br, mlucas@uricer.edu.br

Abstract. Introduction: *Efficient product retrieval in commercial databases is a recurring challenge, especially when users provide incomplete or imprecise descriptions.*

Objective: *To develop an item retrieval system assisted by a pre-trained language model adapted to a specific domain.*

Methodology: *Exploratory research involving literature review, domain adaptation of a pre-trained model using efficient fine-tuning techniques, prototype development, and validation through comparative tests.*

Expected Results: *To improve interpretation of user queries, identify missing search requirements, and increase the relevance of retrieved items.*

Keywords LLM, Fine-Tuning, Recuperação de Informação, Inteligência Artificial, Banco de Dados.

Resumo. Introdução: *A busca eficiente por produtos em bases de dados comerciais é um desafio recorrente, especialmente quando os usuários utilizam descrições incompletas ou imprecisas.*

Objetivo: *Desenvolver um sistema de recuperação de itens baseado em um modelo de linguagem pré-treinado adaptado a um domínio específico.*

Metodologia: *Pesquisa exploratória com revisão bibliográfica, adaptação de modelo pré-existente por técnicas eficientes de fine-tuning, desenvolvimento de protótipo e validação por meio de testes comparativos.*

Resultados Esperados: *Melhorar a interpretação das consultas, identificar requisitos ausentes e aumentar a relevância dos itens retornados.*

Palavras-Chave LLM, Fine-Tuning, Recuperação de Informação, Inteligência Artificial, Banco de Dados.

1. Introdução

O avanço das tecnologias digitais e o crescimento do comércio eletrônico têm ampliado significativamente o volume de dados disponíveis em bases comerciais. Nesse contexto, sistemas de busca desempenham papel fundamental na recuperação eficiente de informações, área tradicionalmente estudada pela Recuperação de Informação [8, 9].

Entretanto, a recuperação de itens ainda apresenta desafios relevantes. Usuários frequentemente utilizam descrições incompletas, termos informais ou informações parciais, dificultando a correspondência direta com dados estruturados.

Diante desse cenário, torna-se necessário investigar abordagens que permitam melhor interpretação das consultas, considerando contexto e intenção. Modelos baseados em Transformers possibilitaram avanços relevantes em tarefas de linguagem natural [2, 3], enquanto abordagens de

embeddings semânticos e recuperação densa ampliaram a capacidade de comparar consultas e documentos por similaridade contextual [10, 11].

Adicionalmente, será desenvolvido um protótipo funcional baseado na adaptação de um modelo de linguagem pré-treinado ao domínio de autopeças, com o objetivo de simular o comportamento de um vendedor especializado. O sistema será capaz de interpretar consultas, identificar requisitos necessários, solicitar informações adicionais quando necessário e realizar buscas estruturadas para retornar itens relevantes.

2. Justificativa

No contexto do comércio de autopeças, a busca por produtos é tradicionalmente realizada de forma manual, a partir da interação entre cliente e vendedor. Nesse processo, o cliente realiza sua solicitação, geralmente por meio de aplicativos de mensagens, e o vendedor interpreta a necessidade e realiza a busca no sistema ERP da empresa.

Entretanto, esse modelo apresenta limitações relevantes. A dependência da interpretação humana torna o processo suscetível a inconsistências, como erros na identificação de peças, influência de preferências pessoais do vendedor (por exemplo, priorização de determinadas marcas) e variação de qualidade conforme a experiência do atendente. Além disso, a necessidade de informações completas para realizar a busca pode gerar atrasos no atendimento, especialmente quando o cliente fornece descrições incompletas ou imprecisas.

Esse cenário é agravado pelo volume de atendimentos. Em situações reais, observa-se uma demanda superior à capacidade operacional da equipe, resultando em clientes não atendidos ou que desistem da compra devido à demora.

Os sistemas atuais, baseados em busca por termos específicos ou aplicações padronizadas, apresentam limitações na interpretação de linguagem natural, exigindo que o usuário forneça descrições estruturadas e completas. Essa abordagem não é compatível com o comportamento real dos clientes, que frequentemente utilizam linguagem informal, incompleta ou ambígua.

Diante desse contexto, justifica-se a aplicação de modelos de linguagem pré-treinados adaptados ao domínio de autopeças, com o objetivo de atuar como um agente conversacional capaz de interpretar consultas em linguagem natural, identificar informações ausentes, interagir com o usuário para complementar os requisitos e realizar a recuperação de itens de forma mais eficiente.

Diferentemente das abordagens tradicionais, a proposta deste trabalho busca não apenas melhorar a busca, mas sim automatizar o fluxo de atendimento, simulando o comportamento de um vendedor especializado. Espera-se, com isso, reduzir o tempo de resposta, minimizar erros na seleção de peças, padronizar o atendimento e aumentar a capacidade de atendimento da empresa, contribuindo diretamente para a melhoria da eficiência operacional e potencial aumento de conversão de vendas.

3. Objetivos

3.1. Objetivo Geral

Desenvolver um sistema de recuperação de itens assistido por um modelo de linguagem pré-treinado adaptado a um domínio específico.

3.2. Objetivos Específicos

- Investigar modelos de linguagem aplicáveis à recuperação de informação em linguagem natural
- Adaptar um modelo pré-treinado ao domínio de autopeças

- Desenvolver um agente conversacional capaz de interpretar consultas e interagir com o usuário
- Implementar mecanismo de identificação e complementação de requisitos de busca
- Integrar o agente a uma base de dados comercial para recuperação de itens
- Construir um protótipo funcional do sistema
- Avaliar o desempenho do sistema em cenários reais de consulta

4. Fundamentação Teórica

4.1. Inteligência Artificial e Agentes

A Inteligência Artificial envolve o desenvolvimento de sistemas capazes de perceber o ambiente, processar informações e executar ações orientadas a objetivos [1]. Neste trabalho, o sistema proposto é tratado como um agente conversacional, pois recebe consultas em linguagem natural, interpreta a intenção do usuário, verifica a suficiência das informações e decide se deve solicitar dados complementares ou executar uma busca estruturada.

4.2. Modelos de Linguagem

Modelos de linguagem são modelos computacionais capazes de representar, interpretar e gerar linguagem natural. A arquitetura Transformer, proposta por [2], tornou-se base para grande parte dos modelos modernos, devido ao uso do mecanismo de atenção para capturar relações contextuais entre termos.

Modelos como BERT [3], GPT-3 [4] e LLaMA [5] demonstram a relevância dos modelos pré-treinados para tarefas de Processamento de Linguagem Natural. Esses modelos podem ser adaptados para tarefas específicas, como classificação, extração de informações, geração de respostas e interpretação de consultas.

4.3. Adaptação de Modelos ao Domínio

Apesar do bom desempenho geral dos modelos pré-treinados, domínios específicos apresentam vocabulário próprio, códigos, abreviações e regras particulares. No domínio de autopeças, a identificação correta de um item pode depender de informações como veículo, ano, motorização, lado de aplicação, marca e código equivalente.

Técnicas de adaptação eficiente, como LoRA [6] e QLoRA [7], permitem ajustar modelos de linguagem com menor custo computacional. Essa característica é adequada para este trabalho, pois o escopo prevê a adaptação de um modelo pré-existente, e não o treinamento de um modelo do zero.

4.4. Recuperação de Informação e Busca Semântica

A Recuperação de Informação trata de métodos para localizar documentos ou registros relevantes a partir de uma necessidade informacional do usuário [8]. Em bases comerciais, esse problema envolve comparar a consulta do usuário com descrições, códigos, aplicações e atributos de produtos.

Abordagens tradicionais baseadas em palavras-chave podem apresentar limitações quando há variação de vocabulário, sinonímia, abreviações ou descrições incompletas. Modelos de embeddings, como o Sentence-BERT [10], permitem representar textos em espaços vetoriais e comparar consultas por similaridade semântica. Já métodos de recuperação densa, como DPR [11], demonstram a viabilidade de recuperar informações relevantes utilizando representações neurais.

4.5. RAG e Integração com Bases de Dados

A Geração Aumentada por Recuperação, ou RAG, combina modelos de linguagem com mecanismos externos de recuperação de informação [12]. Embora este trabalho não tenha como foco principal a geração livre de respostas, o conceito é relevante porque reforça a necessidade de conectar o modelo a uma base de conhecimento estruturada, evitando que a resposta dependa apenas do conhecimento interno do modelo.

No contexto proposto, o modelo de linguagem deve apoiar a interpretação da consulta e a condução do diálogo, enquanto a recuperação efetiva dos itens deve ocorrer sobre a base comercial. Assim, busca-se manter rastreabilidade, controle sobre os dados retornados e maior confiabilidade na seleção dos produtos.

5. Escopo

Este trabalho tem como foco o desenvolvimento de um sistema de recuperação de itens em bases comerciais, utilizando um modelo de linguagem pré-treinado adaptado a um domínio específico.

Inclui:

- Desenvolvimento de um sistema de busca assistido por modelo de linguagem adaptado
- Interpretação de consultas em linguagem natural
- Identificação de requisitos de busca a partir da intenção do usuário
- Integração do modelo com banco de dados para recuperação de itens

Não inclui:

- Treinamento de modelo de linguagem do zero
- Desenvolvimento de um sistema comercial completo ou ambiente de produção

6. Metodologia

Este trabalho caracteriza-se como uma pesquisa exploratória e aplicada. É exploratória por investigar o uso de modelos de linguagem na recuperação de itens em bases comerciais, e aplicada por propor o desenvolvimento de um protótipo funcional para o domínio de autopeças.

1. Levantamento de requisitos e fundamentação teórica

Nesta etapa será realizada a revisão bibliográfica sobre recuperação de informação, modelos de linguagem e técnicas de adaptação. Também serão analisados:

- Modelos base mais adequados ao problema
- Estratégias de adaptação ao domínio
- Requisitos técnicos de infraestrutura (hardware e servidor)

2. Desenvolvimento de protótipo de validação

Com base no levantamento técnico, será desenvolvido um protótipo inicial com o objetivo de validar as decisões arquiteturais. A proposta considera uma arquitetura híbrida, na qual um modelo de linguagem será utilizado para auxiliar na interpretação das consultas em linguagem natural, enquanto mecanismos determinísticos serão responsáveis pela validação dos critérios de busca e integração com a base comercial.

A Figura 1 apresenta uma visão geral da arquitetura proposta para o sistema de recuperação de itens.

Esta etapa inclui:

- Adaptação de um modelo pré-treinado ao domínio de autopeças




Figura 1. Fluxo conceitual da arquitetura híbrida proposta.

- Implementação da lógica de interpretação de consultas
- Identificação e validação de critérios necessários para a busca
- Integração com base de dados
- Construção do fluxo de recuperação de itens

3. Desenvolvimento do sistema final

Após validação do protótipo, será realizada a evolução para uma versão mais estruturada do sistema, contemplando:

- Refinamento da arquitetura
- Melhoria da interpretação semântica
- Otimização da recuperação de itens

4. Validação e testes

Serão realizados testes utilizando consultas reais, incluindo:

- Consultas incompletas
- Consultas ambíguas
- Avaliação da relevância dos resultados retornados

Essa etapa visa medir o desempenho do sistema e sua capacidade de simular um atendimento comercial automatizado.

7. Ferramentas

7.1. Hardware

- Computador pessoal para desenvolvimento e testes
- Servidor ou máquina virtual para execução dos modelos e serviços

7.2. Software

- Python
- PostgreSQL
- Docker
- Modelo de Linguagem Pré-treinado (LLM)
- APIs
- Git

Cronograma

[illegible]

8. Resultados Esperados

Espera-se que o sistema desenvolvido seja capaz de interpretar consultas em linguagem natural, mesmo quando estas forem incompletas, imprecisas ou ambíguas, refletindo de forma mais fiel o comportamento real dos clientes no contexto comercial. Além disso, o sistema deverá identificar informações ausentes durante o processo de busca, sendo capaz de interagir com o usuário para complementar os requisitos necessários à recuperação adequada dos itens.

Com a aplicação dessa abordagem, espera-se uma redução no tempo médio de atendimento em comparação ao processo manual atualmente realizado por vendedores, bem como uma diminuição na ocorrência de erros relacionados à seleção de peças. Adicionalmente, o sistema tende a promover a padronização do processo de busca, reduzindo variações decorrentes da experiência ou de decisões subjetivas dos atendentes.

Por fim, espera-se que a solução proposta contribua para o aumento da capacidade de atendimento simultâneo, permitindo que um maior número de clientes seja atendido de forma eficiente, o que pode impactar positivamente a conversão de vendas e a eficiência operacional do ambiente comercial.

9. Referências

Referências

- [1] RUSSELL, Stuart; NORVIG, Peter. *Artificial Intelligence: A Modern Approach*. 4. ed. Pearson, 2021.
- [2] VASWANI, Ashish et al. Attention Is All You Need. In: *Advances in Neural Information Processing Systems*. 2017.
- [3] DEVLIN, Jacob et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics*. 2019. p. 4171–4186.
- [4] BROWN, Tom B. et al. Language Models are Few-Shot Learners. In: *Advances in Neural Information Processing Systems*. 2020. v. 33, p. 1877–1901.
- [5] TOUVRON, Hugo et al. LLaMA: Open and Efficient Foundation Language Models. *arXiv preprint arXiv:2302.13971*, 2023.
- [6] HU, Edward J. et al. LoRA: Low-Rank Adaptation of Large Language Models. *arXiv preprint arXiv:2106.09685*, 2021.
- [7] DETTMERS, Tim et al. QLoRA: Efficient Finetuning of Quantized LLMs. In: *Advances in Neural Information Processing Systems*. 2023.
- [8] MANNING, Christopher D.; RAGHAVAN, Prabhakar; SCHUTZE, Hinrich. *Introduction to Information Retrieval*. Cambridge: Cambridge University Press, 2008.
- [9] BAEZA-YATES, Ricardo; RIBEIRO-NETO, Berthier. *Recuperação de Informação: Conceitos e Tecnologia das Máquinas de Busca*. 2. ed. Porto Alegre: Bookman, 2013.
- [10] REIMERS, Nils; GUREVYCH, Iryna. Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. In: *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*. 2019. p. 3982–3992.
- [11] KARPUKHIN, Vladimir et al. Dense Passage Retrieval for Open-Domain Question Answering. In: *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing*. 2020. p. 6769–6781.
- [12] LEWIS, Patrick et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. In: *Advances in Neural Information Processing Systems*. 2020. v. 33, p. 9459–9474.
- [13] YAO, Shunyu et al. ReAct: Synergizing Reasoning and Acting in Language Models. In: *International Conference on Learning Representations*. 2023.